



Fundação Universidade Federal do ABC
Pró-reitoria de pesquisa
Av. dos Estados, 5001,
Santa Terezinha, Santo André/SP, CEP 09210-580
Bloco L, 3º Andar, Fone (11) 3356-7617
iniciacao@ufabc.edu.br

Relatório Final de Iniciação Científica referente ao Edital:
01/2024 (PIC/PIBIC/PIBITI/PIBIC-AF)

Nome do aluno: Sarah Fernandes de Souza

Assinatura do aluno:

Nome do orientador: Prof. Dr. John Andrew Sims

Assinatura do orientador:

Título do projeto: Desenvolvimento de um Software para Avaliação da Homogeneidade e Relação Sinal/Ruído em Scanners de Imagens por Ressonância Magnética.

Palavras-chave do projeto: Ressonância magnética, RSR, homogeneidade, uniformidade, testes periódicos, garantia de qualidade.

Área do conhecimento do projeto: Engenharia Biomédica

Bolsista: Não

Cidade: São Bernardo do Campo

Data: 20 de setembro de 2025

Sumário

1	Resumo	3
2	Introdução	4
2.1	Bobinas de Radiofrequência	4
2.2	Controle de qualidade	4
2.3	Homogenidade, Constraste e Coeficiente de variação	5
2.4	Características do Ruído em RM	6
2.5	Relação sinal ruído (RSR)	6
2.6	Distorções geométricas	7
2.7	Transformada de Hough	8
2.8	Método de Otsu	8
3	Objetivos	8
4	Metodologia	8
4.1	Materiais	8
4.1.1	Imagens disponíveis para análise	8
4.1.2	Recursos computacionais	9
4.2	Fluxograma	9
4.2.1	Leitura e Visualização das imagens	9
4.2.2	Análise do ruído	9
4.2.3	Filtragem das imagens	11
4.2.4	Limiarização da imagem	12
4.2.5	Detecção de círculos	12
4.2.6	Indicadores de Qualidade	12
4.2.7	Entradas	13
4.2.8	Saídas	13
5	Resultados e Discussão	13
6	Conclusão	16
7	Referências	17
8	Anexos	19

1 Resumo

As imagens médicas de ressonância magnética (IRM) são importantes na medicina para fins diagnósticos, mas a sua qualidade pode ser comprometida por ruído e artefatos. Estas causas de menor qualidade resultam de diversos fatores, como, por exemplo, a agitação térmica dos elétrons do scanner e dos tecidos do paciente, inhomogeneidade do campo magnético e artefatos (por exemplo, movimento do paciente, batimento cardíaco), o que pode impactar na confiabilidade do diagnóstico. Por isso, testes de controle de qualidade são realizados em scanners pré-clínicos e clínicos em que indicadores são extraídos das imagens adquiridas. A determinação de indicadores é dificultada pela falta de padronização da análise e a ausência de softwares que processam as imagens de forma automatizada. Assim, o cálculo de indicadores é feito manualmente, resultando em variância inter e intraoperador, suscetível a erros, e que demanda tempo do operador para executar. O objetivo é desenvolver um software de processamento de imagens capaz de determinar automaticamente medidas quantitativas da qualidade da imagem, possibilitando assim a avaliação do funcionamento dos equipamentos. As imagens volumétricas utilizadas no projeto foram adquiridas por bobinas de um único canal, de tipo milipede e solenóide, em conjunto com fantasmas esféricos, compostos de sulfato de cobre com sal comum, num scanner pré-clínico de 9,4T (Bruker Biospec 94/30, Ettlingen, Germany), localizado no Departamento de Neurobiologia, Universidade de Pittsburgh, EUA. Um pipeline de processamento de imagens foi desenvolvido, capaz de ler, avaliar, filtrar, segmentar e calcular indicadores com finalidade de quantificar a qualidade de imagens. Foram calculados os seguintes indicadores: distorção geométrica, relação sinal-ruído (RSR), homogeneidade, contraste, coeficiente de variação, o grau de estacionariedade de ruído e grau de esfericidade da região do fantoma nas imagens. O programa fornece ao usuário imagens para inspeção visual e dois arquivos com valores separados por vírgulas (.csv) contendo os resultados dos indicadores, os quais podem ser analisados com outros softwares. Um dos arquivos contém o grau de distorção da fatia central do fantoma esférico, e o outro, os indicadores para todos os cortes válidos. O software de análise de IRM foi disponibilizado no Github. Utilizando este software, valores dos indicadores de qualidade, como RSR, homogeneidade, contraste e coeficiente de variação, foram extraídos das imagens, tabelados e visualizados em gráficos. Embora a interpretação das métricas requira conhecimento especializado para serem corretamente interpretadas, o software desenvolvido facilita a comparação de imagens de fantoma ao longo do tempo, o que possibilita a monitoração de mudanças no sistema ou ambiente. Atualmente não temos os dados necessários para efetuar estes estudos. A aquisição destes conjuntos de imagens históricos, da mesma instrumentação, para efetuar estudos na escala de horas, semanas ou meses, que podem gerar insights valiosos para especialistas que mantêm ou desenvolvem a instrumentação; validação e refatoração do código, e a adição de funcionalidade no software para avaliar a distribuição do ruído. Finalmente, o software possui a opção de processar IRM de bobinas multicanal, e queremos adquirir e obter resultados por estes conjuntos de imagens. Um pipeline de processamento de imagens em Python foi desenvolvido para análise de IRM de fantasmas, adquiridas com bobinas de canal único. O software é capaz

de tratar as imagens antes da extração automatizada de indicadores de qualidade, que garante a padronização dos passos de tratamento, antes da extração automatizada dos indicadores de qualidade, reduzindo variação inter e intra-operadora, e reduzindo o tempo de análise das imagens.

2 Introdução

RM é uma modalidade de imagem médica não invasiva que não utiliza radiação ionizante. A ocorrência do fenômeno de ressonância na matéria foi descoberta por Felix Bloch e por Edward Purcell em 1946 e a primeira imagem foi reportada por Paul Lauterbur em 1973. O princípio de funcionamento consiste na interação dos spins de átomos com número ímpar de prótons e nêutrons com três tipos de campos magnéticos, sendo eles, o campo magnético principal, chamado de B_0 , o campo de radiofrequência, responsável pela excitação dos spins e os campos de gradientes lineares, importantes para a seleção das fatias (NISHIMURA, 2010). No processo de aquisição das imagens utilizam-se as bobinas, responsáveis pela geração e/ou recepção dos sinais de radiofrequência (GRUBER et al., 2018).

2.1 Bobinas de Radiofrequência

As bobinas de radiofrequência (RF) são componentes que transmitem potência de RF (excitam os núcleos de hidrogênio do corpo) e também recebem sinais de RF (detectam o sinal emitido do núcleo). Dentre os tipos de bobinas que existem, há as transmissoras, as receptoras e as transceptoras (transmissoras e receptoras). Elas também podem ser categorizadas de acordo com a geometria e a região do corpo na qual são utilizadas, como por exemplo de volume, de superfície e multicanais (GRUBER et al., 2018).

2.2 Controle de qualidade

O controle de qualidade (CQ) de imagens médicas na clínica ou no hospital é essencial para garantir que a instrumentação está operando de forma adequada, produzindo imagens com qualidade suficiente para fins de diagnóstico ou encaminhamento do paciente para tratamento apropriado (DOMINGOS, 2020; ACR, 2015). Normas nacionais e internacionais existem para determinar quais testes devem ser realizados na instrumentação, com qual frequência e os resultados mínimos para garantir sua conformidade (NEMA, 2008; ANVISA).

RM, assim como as outras modalidades, está sujeita a problemas de deterioração da qualidade, o que pode estar relacionado com limitações de hardware, duração do exame, movimentação do paciente, interações do paciente com os componentes elétricos, Eddy current e movimentação estocástica de elétrons livres presentes nas bobinas de RF. As consequências são a adição de ruídos e artefatos às imagens (AJA-FERNÁNDEZ; VEGAS-SÁNCHEZ-FERRERO, 2016). Imagens de fantasmas são utilizadas para avaliar a qualidade das imagens, porém, a análise pode ser demorada, pois, frequentemente, os responsáveis por ela não dispõem de ferramentas especí-

ficas, recorrendo a métodos qualitativos ou verificações visuais para identificar possíveis quedas na qualidade da imagem que possam requerer manutenção.

2.3 Homogeneidade, Contraste e Coeficiente de variação

A homogeneidade descreve a uniformidade dos valores de intensidade dos pixels. Existem várias abordagens para quantificá-la, como o uso de estatísticas de primeira ordem, entropia ou através de análises de textura. No caso da análise de textura, extrai-se a Matriz de Co-ocorrência de Níveis de Cinza (GLCM) e, a partir dela, avalia-se a proximidade dos valores da diagonal principal da matriz. O valor da homogeneidade aumenta à medida que os pixels vizinhos apresentam pouca variação de intensidade entre si, refletindo um campo B1 mais homogêneo (SCIKIT-IMAGE; LANCASTER; HASEGAWA, 2020). A equação 1 mostra a expressão do cálculo de homogeneidade.

$$Homogeneidade = \sum_{i,j} \frac{P(i,j)}{1+(i-j)^2} \quad (1)$$

Onde:

- $P(i, j)$ é o elemento na linha i e coluna j da Matriz de Co-ocorrência de Níveis de Cinza (GLCM) normalizada. Ele representa a probabilidade de um pixel com nível de cinza i ocorrer adjacente a um pixel com nível de cinza j .
- i e j são os números da linha e da coluna, respectivamente.

O contraste é uma medida que se refere à capacidade de diferenciar tecidos ou objetos vizinhos. No contexto de análise de textura, o contraste mede a intensidade das variações locais. Um valor de contraste mais alto indica maiores diferenças entre as intensidades de pixels adjacentes (SCIKIT-IMAGE; LANCASTER; HASEGAWA, 2020). A equação 2 mostra a expressão do cálculo de contraste.

$$Contraste = \sum_{i,j} P(i, j) \cdot (i - j)^2 \quad (2)$$

Onde:

- $P(i, j)$ é o elemento na linha i e coluna j da Matriz de Co-ocorrência de Níveis de Cinza (GLCM) normalizada. Ele representa a probabilidade de um pixel com nível de cinza i ocorrer adjacente a um pixel com nível de cinza j .
- i e j são os números da linha e da coluna, respectivamente.

O coeficiente de variação avalia o quanto de variação há entre os valores dos pixels da imagem. Considerando que o fantoma é feito de material homogêneo, espera-se que a variação seja a menor possível. A equação 3 mostra a expressão para cálculo do coeficiente de variação. A equação 3 mostra a expressão para o cálculo do coeficiente de variação.

$$CV = \frac{\sigma}{\mu} \cdot 100\% \quad (3)$$

Onde:

- σ é o desvio padrão dos valores de tons de cinza dos pixels presentes na imagem.
- μ é a média dos valores de tons de cinza dos pixels presentes na imagem.
- Esses valores podem ser obtidos a partir do histograma da imagem e para o seu cálculo considerou-se apenas a região de sinal.

2.4 Características do Ruído em RM

O processo de aquisição em RM inicia-se com a coleta de dados no espaço-k, um domínio de frequência onde o sinal é amostrado como valores complexos. Neste domínio, o ruído segue uma distribuição Gaussiana (CAMPOS, 2020). Para obter a imagem final para visualização e análise clínica, aplica-se aos valores em espaço-k a transformada inversa de Fourier, resultando em uma "imagem magnitude". A partir deste ponto, a natureza estatística do ruído se altera: enquanto no espaço-k e na imagem complexa o ruído é Gaussiano, na imagem magnitude ele passa a seguir distribuições específicas. Para bobinas de um canal, o ruído segue a distribuição de Rayleigh (AJA-FERNÁNDEZ; VEGAS-SÁNCHEZ-FERRERO, 2016). E para sistemas multicanais, a distribuição do ruído é modelada pela distribuição non-central Chi, devido à combinação matemática dos sinais provenientes de múltiplas bobinas (CAMPOS, 2020).

Na RM, o ruído também pode ser classificado em estacionário e não estacionário. O primeiro refere-se aos casos em que a variância é constante em toda a imagem, o que é típico de aquisições com bobina de canal único ou múltiplas bobinas não correlacionadas combinadas por soma dos quadrados (SoS), resultando em distribuições Rician ou non-central chi estacionárias. Por outro lado, o ruído não estacionário apresenta variância espacialmente variável, fenômeno comum em sistemas multicanais com correlações entre bobinas ou quando técnicas de imagem paralela, como SENSE ou GRAPPA, são empregadas na reconstrução, produzindo distribuições Rician ou non-central chi não estacionárias (AJA-FERNÁNDEZ; VEGAS-SÁNCHEZ-FERRERO, 2016).

2.5 Relação sinal ruído (RSR)

A relação sinal/ruído (RSR) é um importante parâmetro para avaliar a qualidade da imagem, e seu cálculo foi realizado usando a equação 4. Na equação, "S" refere-se ao valor médio dos pixels na MROI (Measurement Region of Interest), que é uma região de interesse contendo o sinal, desenhada sobre a área do fantoma para medir a intensidade do sinal. Esta MROI deve cobrir pelo menos 75 % da região de sinal do fantoma, e seu valor é indicado como " $\mu(MROI)$ ". O valor "N" denota o desvio padrão do ruído, medido na NMROI (Noise Measurement Region of Interest), uma região que contém apenas ruído. A NMROI é desenhada no fundo da imagem, sem incluir o fantoma e longe de quaisquer artefatos, com o propósito de medir o desvio padrão




Figura 1: Imagem mostrando a distribuição de ruído esperada. Na região de sinal é a distribuição Riciana e na região de ruído de Rayleigh, para casos em que a bobina utilizada possui apenas um canal (Fonte: AJA-FERNÁNDEZ; VEGAS-SÁNCHEZ-FERRERO, 2016).

do ruído, indicado na equação como “ $\sigma(NMROI)$ ” (NEMA, 2008).

$$RSR = \frac{\mu(MROI)}{\sigma(NMROI) \cdot 0,66} = \frac{S}{N \cdot 0,66} \quad (4)$$

Onde:

- MROI: Região de interesse que engloba a porção da imagem que possui valores relacionados à estrutura imagiada.
- NMROI: Região cuja área é composta por valores aleatórios que não representam nenhuma estrutura de interesse dentro do corpo humano.
- S ou $\mu(MROI)$: Média dos valores dos tons de cinza dos pixels dentro da MROI.
- N ou $\sigma(NMROI)$: Desvio padrão dos valores de tons de cinza dentro da NMROI.
- Fator de correção (0,66): A MROI possui uma distribuição Rician, que pode ser aproximada por uma Gaussiana, mas a NMROI apresenta a distribuição Rayleigh. Portanto, aplica-se um fator para corrigir seu desvio padrão, ajustando-o ao de uma distribuição Gaussiana.

2.6 Distorções geométricas

Distorções geométricas são alterações ou deformações na forma, tamanho ou posição dos objetos representados devido ao deslocamento dos pixels em relação à posição esperada. Alguns dos principais fatores são a inhomogeneidade do campo magnético principal e gradientes não lineares (DOMINGUES, 2020). Problemas com distorção modificam a representação da estrutura, reduzindo a precisão e prejudicando o diagnóstico (ACR, 2015). A detecção delas pode ser feita a partir da comparação das dimensões do fantoma nas imagens com as reais.

2.7 Transformada de Hough

A transformada de Hough (HOUGH, 1962), que foi generalizada por Duda e Hart (DUDA; HART, 1972) para geometrias além de linhas retas, é um método para encontrar possíveis formas, como círculos, em uma imagem a partir do seu mapa de bordas (por exemplo, saída do detector de bordas de Canny).

A transformada de Hough para círculos detecta especificamente círculos mapeando pontos de borda em um espaço de parâmetros que representa os centros e os raios dos círculos. Para o seu cálculo são necessários três parâmetros, sendo eles duas coordenadas “x” e “y” e o raio da circunferência (OPENCV). Equação 5 mostra a expressão utilizada para representar os círculos que são calculados por meio da transformada de Hough.

$$C_{Hough}(x_{centro}, y_{centro}, r_{raio}) \quad (5)$$

2.8 Método de Otsu

O método de Otsu é um algoritmo para limiarização automática que separa os pixels de uma imagem em duas classes. Ele encontra um limiar ótimo num sentido estatístico, ao maximizar a variância interclasse dos níveis de cinza (OTS, 1979; Gonzalez e Woods, 2018). A imagem pode ser então dividida em dois grupos: pixels com nível de cinza abaixo do limiar recebem um valor (como 0, preto) e os que estão acima recebem outro (como 1, branco), o que resulta em uma máscara binária.

3 Objetivos

O objetivo deste trabalho é desenvolver um software de processamento de imagens capaz de determinar automaticamente medidas quantitativas da qualidade da imagem.

4 Metodologia

4.1 Materiais

4.1.1 Imagens disponíveis para análise

As imagens disponibilizadas foram feitas com o uso de três tipos de bobinas de RF, porém, apenas a milipede foi utilizada na elaboração do código.

- Volumétrica - tipo milipede com 30 mm de diâmetro interno (**Figura 1a**);
- Volumétrica - tipo solenóide com 30 mm de diâmetro interno (**Figura 1b**);
- Multicanal com 8 canais exclusivos para recepção com base nos protocolos sugeridos pela ACR e pelo NEMA (**Figura 1c**).




Figura 2: Imagens das três bobinas utilizadas para aquisição dos três conjuntos de imagens. (a) Bobina volumétrica millipede (esquerda), (b) Bobina volumétrica solenóide (central) e (c) Bobina multicanal com 8 canais receptora (direita).

O fantoma utilizado possui formato esférico com diâmetro de 25 mm e foi preenchido com solução aquosa de $CuSO_4$ (1 g/L) e NaCl (3,6 g/L), apresentando distribuição homogênea. Este foi posicionado na região central e mais homogênea de cada bobina, chamada de isocentro. As imagens foram coletadas a partir de um scanner pré-clínico de 9,4T (Bruker Biospec 94/30, Ettlingen, Germany), localizado no Department of Neurobiology, University of Pittsburgh, EUA.

As imagens do fantoma foram realizadas com as três bobinas, solenóide, millipede e 8 canais, foram adquiridas com ponderação em T1, e sequência de pulsos spin-eco com $TR = 500$ ms e $TE = 20$ ms. O campo de visão das aquisições (Field of View, FOV) foi de $50 \text{ mm} \times 50 \text{ mm}$ e 1 mm de espessura de fatia, com tamanho de matriz 256×256 e 30 fatias no total.

4.1.2 Recursos computacionais

Todo o código foi desenvolvido em Python 3.12.11 utilizando bibliotecas científicas e utilitárias padrão, como: skimage, pandas, glob, OpenCV, imageio, matplotlib, pydicom e numpy. OpenCV.HoughCircles implementa o HCT. O ambiente ou IDE utilizado para testar e rodar os códigos foi o Google Colab. O computador utilizado possui CPU Intel Core i7, 16GB de memória RAM e placa de vídeo Intel Iris Xe.

4.2 Fluxograma

O fluxograma das funções pode ser observado na figura 4 e cada uma delas será explicada a seguir.

4.2.1 Leitura e Visualização das imagens

A entrada da função de leitura são duas strings com os caminhos do arquivo da imagem e do ruído e a saída as informações das imagens e do ruído. A visualização pode ser realizada, por meio de plots (função "plotagemimagens"), ou vídeo (função "videoimagens").

4.2.2 Análise do ruído

A avaliação do ruído nas imagens foi realizada por meio da seleção de 4 regiões, chamadas de "NMROI", que são partes da imagem que não apresentam sinal, apenas ruído (NEMA, 2008).

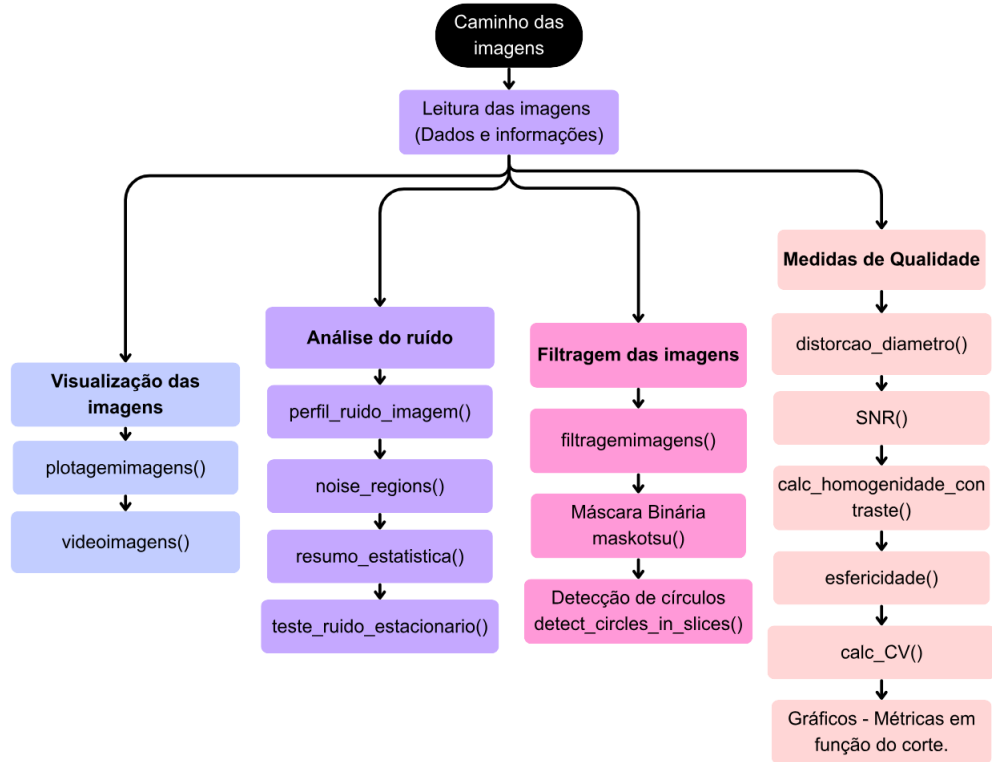


Figura 3: Fluxograma das funções que mostra, de forma geral, todo o funcionamento do código, desde a leitura das imagens até o retorno do resultado final ao usuário. Na imagem, estão as funções voltadas para a visualização das imagens, as relacionadas à análise do ruído, um conjunto relacionado à filtragem das imagens (de forma direta ou indireta) e o último bloco está relacionado aos resultados e às métricas.

Nelas, a distribuição do ruído é "Rayleigh", mas apenas para bobinas de um canal (CAMPOS, 2020). A figura 4 mostra a seleção das quatro regiões.




Figura 4: Imagem do fantoma obtida com a bobina millipede de um canal. Na imagem é possível observar em vermelho 4 regiões selecionadas, cada uma delas equivale a uma ROI que possui apenas ruído (Fonte: Autor).

- **Distribuição dos ruídos das regiões:** Para um sistema com um canal, o ruído é estacionário, ou seja, varia com a intensidade do sinal, mas não varia com a posição do pixel e o desvio padrão e a média das regiões devem ser próximos (AJA-FERNÁNDEZ;

VEGAS-SÁNCHEZ-FERRERO, 2016).

- **Seleção dos pixels:** Os pixels selecionados não podem abranger a região com sinal e as normas na NEMA, aconselha a seleção de ao menos 1000 pixels. Cada ROI possui 250 pixels de área, que somados, dão os 1000 pixels necessários (NEMA, 2008).
- **Ruído na região de sinal (MROI):** O ruído na ROI que engloba o sinal deve ter uma distribuição chama de RICIANA (NEMA, 2008).
- **Ruído na região de ruído (NMROI):** O ruído nas NMROI é um caso particular do ruído RICIANO, chamado de RAYLEIGH (NEMA, 2008).

A análise do ruído envolve algumas funções e análises:

1. Função "**perfil_ruído_imagem**": Essa função recebe os dados do ruído, e devolve três plots; (i) histograma geral do ruído (considerando a média de todos os cortes), (ii) a função densidade de probabilidade (PDF) e (iii) a função de distribuição acumulada (CDF). O objetivo desses plots é a visualização da distribuição do ruído.
2. Função "**noise_regions**": Seleciona 4 regiões para a análise do ruído e fornece dados de desvio padrão e média das 4 NMROIs. O ruído deve possuir variância uniforme no caso de bobinas de um canal.
3. Função "**resumo_estatistica**": Realiza os cálculos de média e desvio padrão de todas as ROIs de cada um dos cortes. Todas elas foram comparadas.
4. Função "**teste_ruído_estacionario**": Aplica o teste do qui-quadrado nas quatro regiões. Se o valor "p" for significativo, então podemos rejeitar a hipótese nula; o ruído nas quatro regiões é diferente. E se o valor "p" não for significativo, o ruído nas quatro regiões pode ser considerado como o mesmo.

4.2.3 Filtragem das imagens

Devido à sua simplicidade, os filtros "box" são indicados para experimentos rápidos e produzem suavização visualmente aceitável, especialmente para preservar bordas (GONZALEZ; WOODS, 2018, p. 167). Contudo, apresentam limitações, como a tendência a causar maior desfoque em direções perpendiculares, o que pode prejudicar imagens detalhadas. Nesses casos, filtros isotrópicos, como os Gaussianos, são preferidos por oferecerem suavização uniforme em todas as direções (GONZALEZ; WOODS, 2018, p. 167). A filtragem foi realizada com filtro gaussiano, que é baseado na distribuição normal, melhorando o desempenho de outras funções, como a de limiarização e a de detecção de bordas.

4.2.4 Limiarização da imagem

O método de Otsu, descrito na seção "Método de Otsu" determina um valor intermediário que melhor separa as regiões de sinal do fundo da imagem. Embora ele forneça um limiar de forma automática, é importante destacar que tanto a área do fantoma quanto o fundo possuem ruído. Dessa forma, a limiarização pode apresentar algumas imprecisões, como possíveis classificações incorretas causadas pela presença de ruído na região de sinal.

4.2.5 Detecção de círculos

A detecção de círculos foi realizada com a transformada de Hough para círculos, descrita na seção "Transformada de Hough", pois os fantasmas utilizados apresentam formato aproximadamente circular. Supondo que não haja distorções extremas, a detecção abrangerá a maior parte da região de sinal.

4.2.6 Indicadores de Qualidade

Indicadores de qualidade fornecem informações quantitativas ou qualitativas que ajudam a medir a qualidade de algum processo. As principais medições realizadas foram:

1. **Distorção do maior diâmetro:** Considerando que o maior diâmetro é conhecido, essa medição avalia o quão próximo do ideal está o maior diâmetro capturado nas imagens.
2. **RSR - Relação sinal ruído:** Cálculo da relação entre o ruído e o sinal da imagem. O objetivo é sempre que o sinal seja maximizado e o ruído minimizado, para que o RSR seja o maior possível.
3. **Homogeneidade e Contraste:** Avalia o quão homogêneos são os valores dentro da região de sinal e se as bordas estão bem definidas.
4. **Limiar utilizado pelo método de Otsu:** Define o valor de tom de cinza utilizado para formação das máscaras binárias.
5. **Esfericidade:** Avalia o quão distante o fantoma está de ser uma esfera, dado que o fantoma é esférico. São calculados dois valores de raio, que deveriam ser iguais. Quanto maior a diferença, mais próximo está de um formato elíptico.
6. **Coeficiente de Variação:** Relacionado à homogeneidade das imagens, quando mais perto de zero, maior é a homogeneidade dentro da região de sinal.
7. **Estacionaridade do Ruído:** Confere se as imagens apresentam ruído estacionário ou não.

O Pipeline completo executa todas as funções descritas em oito etapas:

- ETAPA 1: Leitura das imagens.

- ETAPA 2: Visualização das imagens.
- ETAPA 3: Análise do ruído.
- ETAPA 4: Filtragem das imagens.
- ETAPA 5: Criação de máscaras binárias.
- ETAPA 6: Detecção de círculos.
- ETAPA 7: Cálculo de métricas.
- ETAPA 8: Compilação dos resultados.

4.2.7 Entradas

Para a execução do pipeline, os seguintes parâmetros são necessários:

- **Caminho da Imagem e do Ruído:** O caminho para os arquivos NIfTI da imagem e do ruído, representados por `imagem_path` e `ruído_path`, respectivamente.
- **Detalhes Geométricos:** O Campo de Visão (FOV) em milímetros, o diâmetro real do objeto em milímetros e a dimensão da matriz em pixels.
- **Dimensão das ROIs:** A dimensão das Regiões de Interesse (ROIs) do ruído, em pixels.
- **Configurações de Saída:** Duas variáveis booleanas controlam a geração de elementos visuais: `mostrar_plots` para exibir gráficos intermediários e `gerar_videos` para criar vídeos do processo.

4.2.8 Saídas

Ao final da execução, o pipeline retorna dois DataFrames do Pandas contendo os resultados da análise:

- **DataFrame Final (`df_final`):** Um DataFrame completo que reúne todas as métricas de qualidade calculadas e organizadas de forma limpa.
- **DataFrame de Diâmetro (`pd_diametro`):** Um DataFrame específico com os resultados detalhados sobre maior diâmetro.

5 Resultados e Discussão

A apresentação dos resultados inicia-se com o processamento dos arquivos de imagem no formato NIFTI. Primeiramente, são extraídas as informações do cabeçalho e as dimensões dos dados para uma verificação inicial, juntamente com uma análise visual dos cortes da imagem

(conforme Figuras 5 e 6). Em seguida, a distribuição do ruído é avaliada por meio de três gráficos: (i) o histograma, (ii) a Função de Densidade de Probabilidade (PDF), calculada a partir da normalização do histograma (para que a área sob a curva some 1), e (iii) a Função de Distribuição Acumulada (CDF), obtida pela soma cumulativa (integração) da PDF. Após essa análise descritiva, as métricas de qualidade quantitativas foram calculadas para cada corte válido, e os resultados estão sumarizados na Tabela 1 para discussão

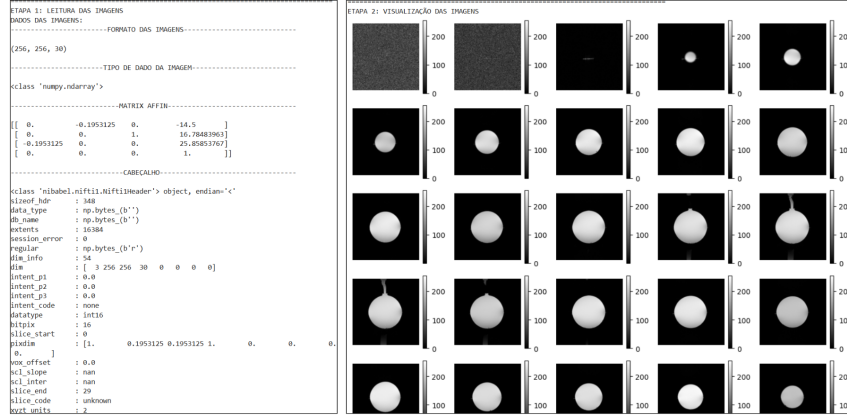


Figura 5: Informações sobre as imagens e cabeçalho (Etapa 1) e cortes das imagens plotadas em um grid (Etapa 2).




Figura 6: Imagem com os gráficos do ruído (Etapa 3): Da esquerda para a direita, há um histograma, a função de densidade de probabilidade (PDF) e a de distribuição acumulada (CDF).

Finalizada a análise do ruído, um filtro Gaussiano é aplicado para suavizar a imagem. Em seguida, utiliza-se o método de Otsu para separar a região de sinal do fundo e a Transformada de Hough para a detecção das bordas circulares do fantoma. Por fim, o pipeline conclui com o cálculo das métricas (Figura 7). Os dados finais (Tabela 1 e Tabela 2) são organizados em dois DataFrames e salvos como arquivos .csv: o primeiro contém os indicadores de qualidade para cada um dos cortes válidos, e o segundo apresenta os dados de distorção do maior diâmetro. Foram consideradas válidas, 24 das 30 fatias, que possuem dimensão 256x256 (pixels).

A análise visual dos gráficos da figura 8 aponta para uma queda na qualidade da imagem nos cortes centrais do fantoma. A região central apresentou menor homogeneidade e menor RSR, indicando que a quantidade de sinal, em relação à de ruído, é menor do que nas extremidades.

```

=====
ETAPA 4: FILTRAGEM DAS IMAGENS - Filtro Gaussiano
Vídeo das imagens filtradas
(256, 256, 30) <class 'numpy.ndarray'>
Maior valor de cinza: 255.0 e menor valor de cinza: 0.7
=====
ETAPA 5: MÁSCARAS BINÁRIAS - Método de Otsu
Vídeo das máscaras
(256, 256, 30) <class 'numpy.ndarray'>
Maior valor de cinza: 1.0 e menor valor de cinza: 0.0
=====
ETAPA 6: DETECTANDO CÍRCULOS - Transformada de Hough
Vídeo da detecção dos círculos
(256, 256, 24) <class 'numpy.ndarray'>
Maior valor de cinza: 252.0 e menor valor de cinza: 0.0
=====
ETAPA 7: CALCULANDO MÉTRICAS
1) Distorção do maior diâmetro
=====DISTORÇÃO DO MAIOR DIÂMETRO=====
Tamanho do pixel: 0.1953125
FOV: 50.00 mm
Diâmetro Real: 25.00 mm
Dimensão do pixel: 0.20 mm/pixels
Diâmetro máximo calculado = 24.61 mm
Porcentagem de Distorção do diâmetro = 1.59 %
=====
2) SNR
3) Homogeneidade e Contraste
4) Homogeneidade e Contraste
5) Esfericidade
6) Coeficiente de Variação
=====

```

Figura 7: Saídas no console referentes à etapa 4 até a etapa 7.

Tabela 1: Métricas de Qualidade por Corte

Corte	Média	Ruído	RSR	RSR (db)	Limiar	Homogeneidade	Contraste	CV	Esfericidade	Estacionário
6	206,44	92,73	2,23	6,95	103,1	0,64	32,07	3,36	98,72 %	Sim
7	216,0	105,67	2,04	6,21	108,08	0,63	46,2	3,74	98,49 %	Sim
8	220,25	114,63	1,92	5,67	110,07	0,61	57,36	4,06	98,55 %	Sim
9	196,06	106,86	1,83	5,27	98,12	0,66	56,74	4,33	98,57 %	Sim
10	213,9	120,71	1,77	4,97	107,09	0,63	73,41	4,46	98,82 %	Sim
11	193,58	112,04	1,73	4,75	97,12	0,65	67,59	4,77	98,7 %	Sim
12	209,46	123,41	1,7	4,59	105,09	0,61	83,34	4,95	98,46 %	Sim
13	219	125,73	1,69	4,55	106,08	0,62	90,89	4,66	98,48 %	Sim
18	216,1	126,3	1,71	4,67	108,08	0,62	87,92	4,43	98,5 %	Sim
19	183,02	104,6	1,75	4,86	92,14	0,66	58,25	4,16	98,49 %	Sim
20	223,14	124,05	1,8	5,1	112,06	0,63	77,76	3,94	98,65 %	Sim
21	208,17	111,3	1,87	5,44	104,09	0,66	59,71	3,67	98,49 %	Sim
22	211,7	107,02	1,97	5,88	106,08	0,66	52,05	3,51	98,61 %	Sim
23	232,84	118,66	2,1	6,46	117,04	0,63	47,65	3,34	98,89 %	Sim
24	182,5	78,94	2,31	7,28	91,14	0,71	24,08	3,21	98,77 %	Sim
25	218,8	82,18	2,66	8,51	110,07	0,65	25,19	3,09	98,43 %	Sim

Mas os valores de contraste e de coeficiente de variação foram maiores nessa região.

Tabela 2: Distorção do Diâmetro

Parâmetro	Valor
Tamanho do pixel (mm)	0,19
FOV (mm)	50,00
Diâmetro real (mm)	25,00
Diâmetro máximo calculado (mm)	24,61
Distorção do diâmetro (%)	1,59

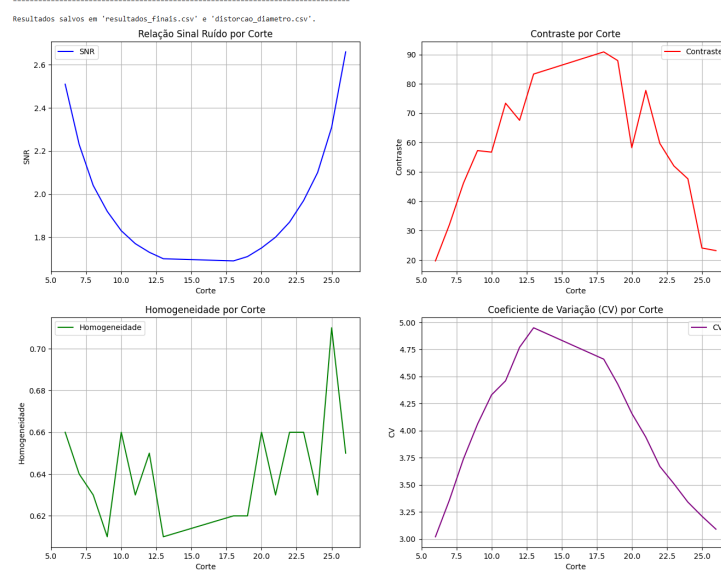


Figura 8: Gráficos com a relação de alguns dos parâmetros (RSR, Contraste, Homogeneidade e CV) em função dos cortes válidos. É possível observar que nem todos os cortes possuem a mesma qualidade, que varia dependendo da região em que o fantoma se encontra dentro do equipamento (Fonte: Autor).

6 Conclusão

Um pipeline de processamento de imagens em Python foi desenvolvido para a análise de IRM de fantasmas, adquiridas com bobinas de canal único. O software padroniza o tratamento das imagens para a extração automatizada de indicadores de qualidade, o que reduz a variação inter e intra-operadora e o tempo de análise.

As limitações do projeto incluem a necessidade de arquivos em formato NIfTI e de um fantoma com geometria circular. Além disso, como os objetos imageados não são perfeitamente circulares, algumas regiões de sinal podem ser indevidamente excluídas da delimitação, enquanto regiões de ruído podem ser incluídas.

Trabalhos futuros incluem a aquisição de imagens históricas para estudos longitudinais, a validação e refatoração do código, a implementação de uma funcionalidade para avaliar a distribuição do ruído e a aplicação do software para processar imagens de bobinas multicanal.

7 Referências

Referências

- [1] **GRUBER, B. et al.** RF coils: A practical guide for nonphysicists. *Journal of Magnetic Resonance Imaging*, v. 48, n. 3, p. 590–604, 13 jun. 2018.
- [2] **BALLARD, D. H.** Generalizing the Hough transform to detect arbitrary shapes. *Pattern Recognition*, v. 13, n. 2, p. 111–122, 1981.
- [3] **CANNY, J.** A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. PAMI-8, n. 6, p. 679–698, 1986.
- [4] **GUDBJARTSSON, H.; PATZ, S.** The Rician distribution of noisy MRI data. *Magnetic Resonance in Medicine*, v. 34, n. 6, p. 910–914, Dec. 1995. DOI: 10.1002/mrm.1910340618.
- [5] **HARALICK, R. M.; SHANMUGAM, K.; DINSTEN, I.** Textural features for image classification. *IEEE Transactions on Systems, Man, Cybernetics*, v. 3, n. 6, p. 610–622, 1973.
- [6] **MAZZOLA, A. A.** Ressonância magnética: princípios de formação da imagem e aplicações em imagem funcional. *Revista Brasileira de Física Médica*, v. 3, n. 1, p. 117–129, 2009.
- [7] **PETROU, M.; SEVILLA, P. G.** *Image Processing: Dealing with Texture*. John Wiley Sons, Ltd, London, 2006.
- [8] **THAKUR, K. V.; DAMODARE, O. H.; SAPKAL, A. M.** Poisson Noise Reducing Bilateral Filter. *Procedia Computer Science*, v. 79, p. 861–865, 2016.
- [9] **GONZALEZ, R. C.; WOODS, R. E.** *Digital Image Processing*. 4. ed. New York, NY: Pearson, 2018.
- [10] **RANGAYYAN, R. M.** Image quality and information content. In: *Biomedical Image Analysis*, chapter 2, p. 39–84. CRC Press, 2005.
- [11] **DOMINGUES, C. V. J.** *Controle da qualidade de imagem em ressonância magnética*. Tese (Mestrado) - Universidade de Lisboa, Portugal, 2020.
- [12] **CAMPOS, V. P.** *Método baseado em estabilização de variância para filtragem de imagens volumétricas de ressonância magnética corrompidas por ruído Riciano não-estacionário*. Dissertação UFSCAR, São Carlos, 2020. Disponível em: <https://www.teses.usp.br/teses/disponiveis/18/18152/tde-02022022-151520/pt-br.php>. Acesso em: 29 set. 2024.
- [13] **AMERICAN COLLEGE OF RADIOLOGY (ACR).** *Quality Control Manual*. Reston, VA, 2015. Disponível em: https://www.researchgate.net/publication/284188389_2015_ACR_MR_QCManual_Table_of_Contents. Acesso em: 16 fev. 2025.

- [14] **BRASIL. Agência Nacional de Vigilância Sanitária (ANVISA).** *Instrução Normativa nº 97, de 03 de dezembro de 2021.* Disponível em: https://bvsms.saude.gov.br/bvs/saudelegis/anvisa/2021/in097_27_05_2021.pdf. Acesso em: 25 maio 2024.
- [15] **NATIONAL ELECTRICAL MANUFACTURERS ASSOCIATION.** *NEMA Standards Publication MS 1-2008 (R2014, R2020): Determination of Signal-to-Noise Ratio (SNR) in Diagnostic Magnetic Resonance Imaging.* Rosslyn, VA, 2008. Disponível em: www.nema.org. Acesso em: 16 fev. 2025.
- [16] **ELSTER LLC.** Website - MRI Questions: Signal-to-Noise Ratio in MRI, 2024. Disponível em: <https://mriquestions.com/index.html>. Acesso em: 29 maio 2024.
- [17] **GITHUB.** GitHub: Where the world builds software. Disponível em: <https://github.com/>. Acesso em: 16 fev. 2025.
- [18] **OPENCV.** Hough Circle Transform. Disponível em: https://docs.opencv.org/3.4/d4/d70/tutorial_hough_circle.html. Acesso em: 16 fev. 2025.
- [19] **STREAMLIT.** Streamlit Library. Disponível em: <https://streamlit.io/>. Acesso em: 16 fev. 2025.
- [20] **SCIKIT-IMAGE.** Plotting grey-level co-occurrence matrix properties. Disponível em: https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_glcmm.html. Acesso em: 16 fev. 2025.
- [21] **NIBABEL.** *NIfTI Images.* Disponível em: https://nipy.org/nibabel/NiftI_images.html. Acesso em: 24 ago. 2025.
- [22] **scikit-image** (equipe de desenvolvimento). *Multi-Otsu Thresholding.* **scikit-image** Documentation, 2025. Disponível em: https://scikit-image.org/docs/0.25.x/auto_examples/segmentation/plot_multiotsu.html. Acesso em: 25 ago. 2025.
- [23] **Nishimura, Dwight G..** *Principles of Magnetic Resonance Imaging.* Stanford University, Stanford, California, 2010.
- [24] **HOUGH, P. V. C..** *Method and means for recognizing complex patterns,* Dec. 1962.
- [25] **DUDA, R. O.; HART, P. E..** *Use of the Hough transformation to detect lines and curves in pictures.* *Communications of the ACM*, 1972.
- [26] **OTS, N..** *Threshold selection method from gray-level histograms.* *IEEE Transactions on Systems, Man, and Cybernetics,*, v. 9, n. 1, p. 62-66, jan. 1979. DOI: 10.1109/TSMC.1979.4310076.

8 Anexos

ANEXO I - Documentação de arquitetura e design do código

Pipeline de processamento de imagens e análise de dados para avaliar a qualidade de imagens de RM no formato NIfTI. O objetivo principal é automatizar a extração de métricas de qualidade, como a RSR, homogeneidade, contraste, distorção geométrica e esfericidade. As principais bibliotecas utilizadas foram a nibabel (para arquivos NIfTI), numpy (para computação numérica), matplotlib e seaborn (para visualização), scikit-image e opencv (para processamento de imagens) e pandas (para manipulação de dados tabulares).

Funções para leitura e visualização de dados		Entrada	Saída
Leituraimagens()	Carrega arquivos NIfTI de imagem e ruído, extraindo dados, matrizes afins e cabeçalhos	Strings (diretórios para os arquivos NifTi).	Tupla contendo os objetos e dados de imagem e ruído.
Dadosimagens()	Imprime metadados e informações de forma para verificação.	Tupla contendo os objetos e dados de imagem e ruído.	Imprime informações das imagens no console.
plotagemimagens()	Plota todas as fatias (slices) de uma imagem em uma grade.	imagem_data (numpy.ndarray)	Exibe uma figura com as imagens plotadas.
videoimagens()	Cria um vídeo a partir das fatias de imagem, oferecendo uma forma alternativa de visualização.	imagem_data (numpy.ndarray)	Vídeo com as imagens
Análise de Ruído		Entrada	Saída
perfilruídoimagem()	Calcula estatísticas globais de ruído (desvio padrão, média) e visualiza seu histograma e funções de distribuição (PDF e CDF)	ruído_data (numpy.ndarray)	Tupla: Desvio, média e ruído. Gráficos: Histograma, CDF e PDF do ruído.
noise_regions()	Extrai quatro Regiões de Interesse (ROIs) de ruído nos cantos da imagem.	Imagem: numpy.ndarray Coordenadas do Zoom str: "True" ou "False" (Plotagem)	roi1, roi2, roi3, roi4 (numpy.ndarray)
resumo_estatistica()	Calcula estatísticas (média e desvio padrão) para cada ROI de ruído e para o conjunto total.	roi1, roi2, roi3, roi4 (numpy.ndarray)	df_estatisticas (pd.DataFrame) roi (numpy.ndarray): ROIs concatenadas
teste_ruído_estacionario()	Realiza um teste de Qui-Quadrado para verificar se o ruído nas ROIs é estatisticamente semelhante, ou seja, se é estacionário.	roi1, roi2, roi3, roi4 (numpy.ndarray)	pd.DataFrame
Processamento e Segmentação de Imagem		Entrada	Saída
filtragemimagens()	Aplica um filtro Gaussiano para suavizar as imagens e reduzir ruído	imagem_data (numpy.ndarray)	imagem_data (numpy.ndarray) filtrado
maskotsu()	Cria uma máscara binária usando o método de limiarização de Otsu, que é fundamental para segmentar o objeto principal da imagem (o phantom).	(numpy.ndarray)	mask_otsu (numpy.ndarray) t_otsu (float)
Métricas de Qualidade		Entrada	Saída
detect_circles_in_slices()	Utiliza a Transformada de Hough para detectar o círculo principal na imagem, medindo seu diâmetro.	imagem_data (numpy.ndarray)	Círculos - (numpy.ndarray) diâmetro - (list)
distorsao_diâmetro()	Calcula a distorção geométrica do diâmetro em porcentagem, usando o diâmetro medido em pixels e o diâmetro real.	diâmetro (list), FOV (int), diâmetro_real (int), matrix_dim (int)	pd_diâmetro (pd.DataFrame)
SNR()	Calcula a Relação Sinal-Ruído (SNR) para cada fatia da imagem, com base na média dos pixels da Máscara de Região de Interesse (MROI) e no desvio padrão do ruído.	imagem_data (numpy.ndarray), mostrar_plots (bool)	df_snr (pd.DataFrame)
calc_homogeneidade_contraste()	Calcula homogeneidade e contraste usando as propriedades da Matriz de Co-ocorrência de Níveis de Cinza (GLCM).	imagem_data (numpy.ndarray)	df (pd.DataFrame)
esfericidade()	Calcula a esfericidade, que é a razão entre os eixos menor e maior de um objeto, usando a biblioteca scikit-image.	mask_otsu (numpy.ndarray), Plotar (bool)	df_esfericidade (pd.DataFrame)
calc_CV()	Calcula o Coeficiente de Variação (CV) para avaliar a uniformidade de sinal dentro do objeto.	mask_otsu (numpy.ndarray), imagem_data (numpy.ndarray)	df (pd.DataFrame)
pipeline_completo()		Descrição	
ETAPA 1	Leitura de Dados	Carrega os arquivos NIfTI	
ETAPA 2	Visualização (Opcional)	Plota ou gera vídeos das imagens.	
ETAPA 3	Análise de Ruído	Calcula estatísticas de ruído e testa a estacionariedade do ruído nas ROIs	
ETAPA 4	Filtragem	Aplica o filtro Gaussiano para pré-processar as imagens.	
ETAPA 5	Máscaras Binárias	Cria a máscara binária (Otsu) para isolar o objeto de interesse	
ETAPA 6	Deteção dos círculos	Detecta círculos para calcular a distorção	
ETAPA 7	Métricas de qualidade	Distorção do maior diâmetro, SNR, Homogeneidade e Contraste, Filtragem e Limiarização com Otsu, Esfericidade, Coeficiente de Variação.	
ETAPA 8	Compilação dos resultados e remoção de Outliers (remove_outliers())	Combina todos os resultados em um único DataFrame e salva em um arquivo CSV.	

ANEXO II - Orientações de Uso

O código está disponível em: [link do Pipeline](#)

1. **Instale as bibliotecas necessárias:** O código possui um conjunto de bibliotecas que precisam ser instaladas antes da utilização do código.
2. **Rodando o código no colab:** Conecte-se ao Google Drive para carregar seus arquivos de imagem e ruído diretamente do Google Drive. Rodando localmente, basta criar um diretório com os arquivos.
3. **Execução do Pipeline:** A função principal para rodar todo o processo é a "pipeline_completo()", que inclui todas as etapas da análise. Para rodar a análise, basta chamar a função passando os caminhos dos seus arquivos NIfTI de imagem e ruído.

```
1 imagem_path = "/content/drive/MyDrive/Solenoide/Image_Phantom.nii"
2 ruido_path = "/content/drive/MyDrive/Solenoide/Noise.nii"
3
4 pipeline_completo(imagem_path, ruido_path, FOV=50, diametro_real=25, matrix_dim=256,
5                   dim_roi=50, mostrar_plots=True, gerar_videos=True)
6
7 #ou
8
9 df_final, pd_diametro = pipeline_completo(imagem_path, ruido_path, FOV=50, diametro_real=25, matrix_dim=256,
10                                          dim_roi=50, mostrar_plots=True, gerar_videos=True)
```

Figura 9: Exemplo de como rodar o Pipeline completo

Parâmetros da função:

- **imagem_path e ruido_path (obrigatório):** Caminho do arquivo NIfTI da imagem e ruído.
- **FOV (opcional):** O Campo de Visão da imagem em milímetros (padrão: 50).
- **diametro_real (opcional):** O diâmetro real do objeto em milímetros (padrão: 25).
- **matrix_dim (opcional):** A dimensão da matriz de pixels da imagem (padrão: 256).
- **dim_roi (opcional):** Dimensão das ROIs de ruído usadas na análise (padrão: 50).
- **mostrar_plots (opcional):** Defina como True para exibir gráficos de todas as fatias. O padrão é True.
- **gerar_videos (opcional):** Defina como True para gerar vídeos das fatias. O padrão é True.

Após a execução, a função retorna e salva dois DataFrames no diretório atual:

- **resultados_finais.csv:** Contém métricas como RSR, homogeneidade, contraste, esfericidade e CV para cada fatia.
- **distorcao_diametro.csv:** Apresenta a distorção geométrica do diâmetro.